

Название: Мультиагентная система для автоматизированного расследования аварий на горнодобывающих предприятиях с использованием больших языковых моделей и аргументационного вывода

Студент: Ридван А. Адебайо

Научный руководитель: доц. Игорь Темкин

Программа: Магистратура по направлению «Наука о данных», НИТУ МИСИС

1. Постановка проблемы и актуальность

Аварии на горнодобывающих предприятиях остаются серьёзной проблемой безопасности во всём мире. Расследование таких инцидентов требует анализа разнородных источников данных: журналов датчиков, записей о техническом обслуживании оборудования, показаний свидетелей, нормативных документов и экологических данных. Современные процессы расследования трудоёмки, часто занимают месяцы и сильно зависят от наличия экспертов. Сложность синтеза гетерогенных источников данных при сохранении прослеживаемых цепочек рассуждений представляет значительную проблему.

Большие языковые модели (LLM) предлагают перспективные возможности для обработки неструктурированного текста и рассуждения на основе доказательств. Однако когда различные аналитические подходы приводят к противоречивым выводам, существующие методы не имеют принципиальных механизмов разрешения конфликтов и генерации объяснений. Следователям нужны не только выводы, но и верифицируемые обоснования, которые могут выдержать юридическую и регуляторную проверку.

Данная диссертация направлена на устранение разрыва между AI-assisted анализом доказательств и требованиями объяснимости формальных процессов расследования.

2. Цели и задачи исследования

Основная цель — разработать и реализовать мультиагентную систему, которая помогает следователям анализировать доказательства аварий на горнодобывающих предприятиях и генерировать структурированные, объяснимые отчёты о расследовании.

Конкретные задачи:

1. **Конвейер обработки доказательств:** Разработать систему, которая принимает гетерогенные источники данных (журналы датчиков, записи о техобслуживании, текстовые отчёты, нормативные стандарты) и создаёт унифицированное представление знаний, подходящее для рассуждений агентов.
2. **Архитектура специализированных агентов:** Спроектировать агентов, которые анализируют доказательства с различных точек зрения (анализ отказа оборудования, человеческий фактор, условия окружающей среды, соответствие нормативным

требованиям), каждый из которых формирует структурированные утверждения с подтверждающими доказательствами.

3. **Разрешение конфликтов на основе аргументации:** Реализовать формальный аргументационный слой, который разрешает конфликты между выводами агентов с использованием отношений атаки/поддержки и вычисляет допустимые заключения на основе семантики аргументации Дунга.
4. **Генерация объяснимых отчётов:** Генерировать отчёты о расследовании, которые включают не только выводы, но и полный граф аргументации, показывающий, как доказательства поддерживают или опровергают каждый вывод.

3. Методология

Этап 1: Обзор литературы и проектирование фреймворка

- Обзор существующих подходов к автоматизированному расследованию инцидентов
- Изучение теории аргументации (абстрактная аргументация Дунга, ASPIC+) и её применения к рассуждениям на основе доказательств
- Проектирование архитектуры системы, интегрирующей RAG, координацию мультиагентов и семантику аргументации

Этап 2: Сбор и предобработка данных

- Сбор публично доступных отчётов об авариях на шахтах (например, база данных MSHA, отчёты Ростехнадзора)
- Разработка конвейеров предобработки для структурированных и неструктурированных данных
- Создание базы знаний по правилам безопасности на горнодобывающих предприятиях и спецификациям оборудования

Этап 3: Реализация системы

- Реализация специализированных агентов с использованием LangChain/LangGraph с возможностями вызова инструментов
- Разработка аргументационного слоя для обнаружения и разрешения конфликтов
- Создание модуля генерации отчётов с трассировкой обоснований

Этап 4: Оценка и валидация

- Оценка системы на исторических отчётах об авариях с известными выводами
- Качественная оценка с экспертами предметной области (при наличии)
- Измерение качества объяснений и согласованности рассуждений

Этап 5: Написание диссертации

- Документирование методологии, реализации и результатов
- Подготовка презентации к защите

. Технический подход

Архитектура агентов:

- Каждый специализированный агент использует RAG для доступа к релевантным знаниям (руководства по оборудованию, стандарты безопасности, похожие прошлые инциденты)
- Агенты производят структурированные выходные данные: {утверждение, доказательство, уверенность, обоснование}
- Вызов инструментов позволяет агентам запрашивать базы данных, выполнять вычисления и извлекать конкретные документы

Аргументационный слой:

- Утверждения от разных агентов отображаются в аргументационный фреймворк
- Отношения атаки идентифицируются при противоречии утверждений (например, «отказ оборудования вызвал аварию» vs. «человеческая ошибка вызвала аварию»)
- Основанная семантика или предпочтительная семантика вычисляет множество допустимых аргументов
- Итоговый отчёт включает граф аргументации как артефакт обоснования

Технологический стек:

- Python, LangChain/LangGraph для оркестрации агентов
- ChromaDB/FAISS для векторного хранилища
- Открытые LLM (LLaMA, Mistral) или API-модели (GPT-4, Claude)
- NetworkX для вычисления графа аргументации

5. Ожидаемые результаты

1. **Практическая система:** Работающий прототип, демонстрирующий AI-assisted расследование аварий с объяснимыми выходными данными
2. **Методологический фреймворк:** Обобщаемый подход к применению мультиагентных рассуждений на основе аргументации к задачам анализа доказательств
3. **Эмпирические выводы:** Результаты оценки эффективности объяснений на основе аргументации для задач расследования